嘉興大學
JIAXING UNIVERSITY
方正为人 勤慎治学

商业数据分析

题　　目：“注”微知著，基于五大联赛体育博彩赔率检验

学　　院：数据科学学院

专业班级：大数据 242

学　　号：2024438945105

姓　　名：林丽婷

完成日期：2026 年 11 月 4 日

评分维度	评分要点（子项及分值）	得分
1. 数据获取合规性与清洗质量（15分）	① 来源合规、白名单方式、合规声明完整（5）；② 数据量达标、抽样方法与随机种子说明（4）；③ 清洗完整、异常/缺失/重复处理、多表对齐（4）；④ 可导出 CSV/JSON/SQLite 复用（2）	
2. 商业分析模型应用深度（20分）	① 模型≥3种、选型与场景匹配（6）；② 计算正确、参数与阈值有业务依据（6）；③ 预测类含置信区间与回测误差（4）；④ 结论与模型一一对应（4）	
3. 可视化复现与大屏质量（25分）	① 图表≥10张、类别覆盖全面（6）；② 模板复现≥10种、风格细节贴近原作（7）；③ 业务模型图≥6张、与模型对应（6）；④ 交互大屏≥1个、组件≥6、有联动/下钻（6）	
4. 代码规范性与文档完整性（10分）	① 目录结构清晰、注释充分（3）；②README 详实、依赖明确（3）；③ 可一键复现（2）；④ 图表命名与索引规范（2）	
5. 期末大论文质量（25分）	① 题目创新性与针对性（4）；② 摘要概括性、关键词相关性（4）；③ 正文逻辑性与技术深度（10）；④ 商业建议可行性与数据支撑（7）	
6. 创新性与商业洞察深度（5分）	① 引入新工具/新方法（2）；② 提出有效商业建议（2）；③ 体现批判性思维（1）	
总 分	**（各维度得分相加）**	

“注”微知著，基于五大联赛体育博彩赔率检验

林丽婷

（嘉兴大学 数据科学学院）

摘　要：体育博彩是价格直接映射概率的消费市场，也是检验有效市场假说的天然实验场。本文基于欧洲七大联赛数万场比赛数据，从商业视角检验其赔率结构与市场效率。首先测算**抽水率**，得出全样本均值 5.61%，15 年累计下降 2.07 个百分点，且英超最低 4.77%、葡超最高 6.82%，表明市场结构性变薄。其次构建**概率校准**与 **K-Means 聚类**，得出 Brier 分数 0.5705，五档偏差全为正，最高档热门实际命中率比隐含概率高出 3.16 个百分点，说明市场系统性低估热门。随后对三种朴素策略回测，得出 **ROI** 分别为-105.61%、-102.67%和-103.13%，且命中率 54.15%的策略反亏最多，证明收益与命中率无关。最后对比逻辑回归与 ARIMA 预测，得出模型样本外仅领先市场 0.0005 Brier，ARIMA 的 MAPE 为 8.22%劣于 7.58%的基准，证明模型无法稳定跑赢抽水成本。

关键词：体育博彩；抽水率；概率校准；K-Means 聚类；ROI

1 引言

1.1 研究背景

体育博彩是少数价格即概率的消费市场之一。基于 Football-Data.co.uk 等公开赛事数据库的长期赔率数据[1] 一场足球比赛的胜平负三个结果，在开赛前就被博彩公司折算成三个赔率，赔率的倒数即市场给出的隐含概率。与股票不同，这里的是离散事件，到期日是 90 分钟，清算价是确定的 0 或 1——这使体育博彩成为检验市场有效性假说[2]最干净的实验场：如果连一场只有三种结果、信息公开、赛前有充分时间定价的事件都无法被系统性战胜，那么更强的有效市场结论在其他资产上就更容易成立。

与此同时，博彩公司本身也是一门生意。它的毛利不来自猜对比赛，而来自抽水率——把三个结果的隐含概率加总，和必然大于 100%，超出的部分就是它在每一注上的理论毛利。抽水率越高，玩家的期望值越差，但过高的抽水会把玩家赶到对手那里。正如 Levitt 在探讨博彩市场组织时所指出的[3],因此抽水率是博彩公司盈利性与竞争力之间最核心的调节旋钮。本文要回答的正是：这个旋钮在过去 15 年里被拧向了哪一边，不同联赛之间差多少，以及在这种抽水下玩家还有没有机会。

1.2 研究目的

本文以 Football-Data.co.uk 公开发布的欧洲七大联赛 15 个赛季赔率与赛果数据为唯一数据源，围绕四个目标展开：

（1）量化抽水率的长期演化：测算 2010/11—2024/25 共 15 季的抽水率轨迹，判断市场是在变厚还是变薄，并给出联赛间的差异谱；

（2）检验市场定价的校准度：用 Brier Score、LogLoss 与概率分档对照，判断市场的隐含概率是总体无偏还是结构性偏斜；

（3）测量投注策略的真实收益：对三种朴素策略做逐注回测，计算 ROI，并与理论返还率对照，说明长期必负的数学来源；

（4）验证市场有效性：构建逻辑回归模型与市场隐含概率做样本外对比，判断「用数据能否稳定跑赢市场」，并给出诚实结论。

1.3 研究意义

学术意义在于以 35981 场比赛检验了有效市场假说。逻辑回归样本外 Brier 仅领先市场 0.0005，ARIMA 预测劣于基准，MAPE 为 8.22%对 7.58%。这些负结果证明该市场信息效率极高。实践意义在于：对博彩公司，抽水率由 7.17%降至 5.10%，意味着盈利模式需从依赖水位转向流量与产品；对投注者，三种盲投策略 ROI 均在负百分之百以上，印证了长期必亏的规律。

2 数据准备与预处理

2.1 数据源介绍

本文数据来自 Football-Data.co.uk，站点首页为 https://www.football-data.co.uk/ ，各国联赛历史数据页为 https://www.football-data.co.uk/englandm.php 等，单赛季单联赛的 CSV 直链形如 https://www.football-data.co.uk/mmz4281/2324/E0.csv 。该站点自 1993 年起持续发布欧洲主要联赛的赛果与赛前赔率，是体育统计研究中被引用最广的公开数据源之一。

本次共下载 105 个 CSV 文件，覆盖英超（E0）、德甲（D1）、西甲（SP1）、意甲（I1）、法甲（F1）五大联赛，以及荷甲（N1）、葡超（P1）两个对照联赛；赛季范围为 2010/11 至 2024/25，日期跨度 2010-08-06 至 2025-05-25。字段分为四组：比赛标识、赛果、技术统计（射门、射正、角球、黄红牌）、以及 11 家博彩公司的赛前赔率（Bet365、Pinnacle、William Hill、Ladbrokes 等），每家给出主胜/平局/客胜三个赔率。

表 2-1 数据字段分组说明

字段组	代表字段	类型	本文口径
比赛标识	Date / HomeTeam / AwayTeam	文本/日期	主键：日期 + 主队 + 客队
赛果	FTHG / FTAG / FTR	数值/类别	派生总进球、大 2.5 球、双方进球、赛果
半场	HTHG / HTAG / HTR	数值/类别	派生「上半场领先」事件
技术统计	HS / AS / HST / AST / HC / AC	数值	射门、射正、角球（2010 年代早期缺失较多）

字段组	代表字段	类型	本文口径
平均赔率	AvgH / AvgD / AvgA	数值	本文主口径：抽水率、隐含概率均基于此
最高赔率	MaxH / MaxD / MaxA	数值	策略回测用（可获取的最优价）
公司赔率	B365H / PSH / WHH / …	数值	11 家公司，用于稳健性对照
大小球	Avg>2.5 / Avg<2.5	数值	大 2.5 球关联规则与第二抽水率

2.2 合规获取方式

数据获取方式为 HTTP GET 静态 CSV 而非网页爬虫：

（1）白名单站点：football-data.co.uk，站点在首页明确声明数据可免费下载用于研究，未设置 robots 限制、未要求注册。

（2）不是爬虫：脚本按「赛季 + 联赛代码」拼出确定的文件 URL，逐一 GET 下载，不解析 HTML、不遍历链接、不模拟浏览器行为。105 个文件总耗时 297.7 秒，平均单文件 2.8 秒，请求间隔天然分散。

（3）全程留痕：`data/raw/_manifest.csv` 逐文件记录 URL、字节数、sha256、获取时间与获取方式，可完整复现。

（4）不涉赌：本文只做历史数据的统计描述与回测，不提供任何投注建议，不接入任何实时赔率接口。

2.3 数据来源合规声明

本人郑重声明：本作业所使用的全部数据均来自 Football-Data.co.uk 的公开下载页面，不含任何需登录、付费、私有或经授权方可访问的数据；获取过程未绕过任何访问控制；数据中不含任何个人身份信息；分析结论仅用于课程学习与学术讨论，不构成投注建议，不用于商业用途。

2.4 数据集概述

合并后的主表 matches_clean.csv 共 35,981 行 × 81 列，另以 SQLite（`football.sqlite`）持久化以便查询。表结构如下：

表 2　数据集结构

表名	类型	行数	主键 / 关联	用途
matches_clean	明细主表	35,981	日期 + 主队 + 客队	全部建模与分析
dim_league	维表	7	PK: 联赛代码	联赛名称映射、五大联赛标记
agg_season	聚合	15	PK: 赛季	赛季趋势、抽水率演化
agg_league	聚合	7	PK: 联赛	联赛对比、雷达、气泡
agg_score	聚合	65	PK: 比分	比分帕累托
agg_calib	聚合	49	PK: (隐含概率分档, 赛果类型)	概率校准
agg_roi	聚合	60	PK: (赛季, 赔率档位)	策略回测矩阵

3 数据清洗与治理

3.1　数据清洗

针对跨赛季列结构不一致的问题，本文编写了三级回退取列器进行口径对齐，并在此基础上执行 6 条清洗规则。最终保留 35,981 场比赛，剔除异常及缺失样本 16 场，剔除率为 0.04%。

表 3-1　数据清洗规则

编号	规则	判定条件	处理方式
C1	日期非法	Date 无法解析或不在 2010-07 至 2025-07	剔除
C2	赛果缺失	FTHG 或 FTAG 为空	剔除（多为腰斩或判罚比赛）
C3	赔率非法	任一平均赔率 ≤ 1.01 或 > 100	剔除（录入错误）
C4	抽水率异常	抽水率 < 0 或 > 25%	剔除（同一场比赛两家公司数据串行）
C5	重复比赛	日期 + 主队 + 客队 完全一致	保留首条
C6	字段缺失	技术统计缺失	置空，不参与相关分析（早期赛季较普遍）

清洗后的基本盘：7 个联赛 15 个赛季共 35,981 场，其中英超、西甲各 5,700 场，意甲 5,699 场，法甲 5,451 场，德甲 4,590 场，荷甲 4,516 场，葡超 4,325 场。

3.2 数据转换

在清洗基础上派生了 10 个指标，其中 3 个是本文的核心口径：

表 3-2 派生指标定义

派生指标	公式	含义
总进球	FTHG + FTAG	大小球分析基础
大 2.5 球	总进球 > 2.5 → 1	主流大小球盘口
双方进球	FTHG > 0 且 FTAG > 0 → 1	BTTS 盘口
隐含主胜概率	1 / 平均主胜赔 × 100	市场对主胜的定价
抽水率	(1/主胜赔 + 1/平局赔 + 1/客胜赔 − 1) × 100	**博彩公司理论毛利率**
主场优势	隐含主胜 − 隐含客胜（百分点）	主场溢价的强弱
最大/最小隐含概率	三概率的极值	冷门/热门识别
赛季	由日期推出（8 月—次年 5 月）	跨年赛季口径统一
月份	由日期推出	赛季内节律
年季序	赛季起始年	时间序列排序

以全样本为例：平均抽水率 5.61%（中位数 5.46%），主胜率 44.90%、平局率 24.94%、客胜率 30.15%，场均进球 2.78 球，大球率 52.49%。这三个赛果比例之和恰为 100%，与抽水率 > 0 并不矛盾——前者是真实发生的频率，后者是赛前定价的加总。

3.3 数据整合

整合逻辑为：以赛季 + 联赛为主键纵向拼接 105 个 CSV，再横向关联联赛维表；聚合层按分析主题分别生成 5 张宽表。由于样本量（35,981 场）在单机内存可完全容纳，本文不做抽样，所有分析都基于全量数据，因此不存在抽样误差；涉及随机性的只有 K-Means 初始化与逻辑回归的 SGD，统一设置随机种子 42 以保证可复现。

4 商业分析模型

本章使用 7 类模型，覆盖定价—结构—校准—分群—收益—关联—预测七个视角。

4.1 模型选型

表 4-1 七类商业分析模型

编号	模型	回答的问题	关键输出
M1	抽水率趋势 + 移动平均	市场在变厚还是变薄	15 季抽水率曲线、环比
M2	比分帕累托 + ABC	哪些比分是主流	65 种比分、A 类 13 种
M3	概率校准（Brier/LogLoss）	市场定价准不准	校准曲线、分档偏差
M4	K-Means 比赛分群	比赛有哪几种「形态」	2 类：闷战局/悬殊局
M5	投注策略回测（ROI）	照策略下注能赚吗	ROI、命中率、赛季矩阵
M6	事件关联规则	哪些结果同时发生	49 条规则、提升度
M7	逻辑回归 vs 市场 + ARIMA	模型能跑赢市场吗	准确率、Brier、MAPE

4.2 参数与阈值设定依据

（1）抽水率定义：采用三结果赔率倒数之和减 1 测算，等价于 1 减返还率，以真实反映博彩公司毛利。

（2）K-Means 取值：扫描 K 取 2 至 8，K=2 时轮廓系数最高达 0.458，且符合赔率空间仅有均势与强弱分明两个主要方向的业务逻辑，故取 K=2。

（3）概率分档：按隐含概率每 4 至 5 个百分点一档，划分 49 个赛果档位与 5 个热门档位，以便直接读取偏差百分点。

（4）回测口径：每注固定 1 单位本金，按最高可得赔率成交，ROI 定义为净利润占总投注额的百分比。

（5）样本外切分：按时间顺序，以前 12 个赛季共 28,784 场为训练集，后 3 个赛季共 7,197 场为测试集，严格避免未来信息泄露。

4.3 模型计算与验证

4.3.1 抽水率的 15 年演化

抽水率由 2010/11 的 7.17% 降至 2024/25 的 5.10%，15 年累计下降 2.07 个百分点，14 次环比中 10 次为负；同期场均进球由 2.70 升至 2.81，主胜率由 46.96% 降至 42.60%。这三项指标共同表明，比赛的不确定性在上升，而市场对不确定性的收费在下降。对博彩公司而言，单注毛利被压缩，需靠交易量弥补；对玩家而言，抽水减少与赛果更难预测相互抵消。

4.3.2 比分帕累托

15 年共出现 65 种比分，频次前 13 种（占 20%）覆盖了 82.04% 的比赛，其中 1-1 最常见，占 11.68%；长尾比分仅占 4.87%。这对正确比分盘口有直接含义：买下这 13 种主流比分虽能将命中率提至 82%，但各注赔率乘积必然高于成本，这正是抽水率在具体盘口上的直接体现。

4.3.3 概率校准

借鉴 Deschamps 和 Gergaud 对足球博彩市场效率的实证思路[4],本文基于市场隐含概率与实际赛果计算校准度，Brier 分数[5] 为 0.5705、LogLoss 为 0.9609，显著优于随机基准。但分档后存在系统性偏差：按热门程度分 5 档，五档偏差全为正，最高 20% 档隐含概率 74.00%，实际命中 77.17%，低估 3.16 个百分点，表明市场系统性低估热门。该现象与经典冷门偏好方向部分相反，本文冷门端偏差为 -1.35% 存在高估，但热门端低估幅度更大。原因在于散户偏好押冷门，博彩公司为平衡头寸压低冷门赔率、抬高热门赔率，使热门实际命中高于隐含成为常态。

4.3.4 比赛分群

基于多元统计中的聚类方法[6]以主胜赔、客胜赔为核心特征聚类，轮廓系数在 K = 2 时最高（0.458），得到两类比赛形态：

表 4-2 两类比赛形态画像（K-Means，K=2）

群名	场次	占比	主胜率	平局率	客胜率	场均进球	抽水率
低效闷战局	30,522	84.83%	38.93%	26.78%	34.29%	2.69	5.63%
强弱悬殊局	5,459	15.17%	78.31%	14.64%	7.05%	3.27	5.51%

低效闷战局占比 84.83%，主胜率仅 38.93%，属均势比赛；强弱悬殊局占比 15.17%，主胜率高达 78.31%。值得注意的是，两类比赛抽水率几乎相同，分别为 5.63% 与 5.51%，说明博彩公司不因比赛悬殊程度调整水位，而是对所有比赛收取相近的过路费。

4.3.5 投注策略回测

对三种「不需要任何预测能力」的朴素策略在全样本上逐注回测，每注 1 单位、共 35,981 注：

表 4-3　三种朴素策略的全样本回测结果

策略	命中率	ROI	累计利润（单位）
盲目主胜	44.90%	-105.61%	-38,000
押最高赔率	20.30%	-102.67%	-36,943
押大热门	54.15%	-103.13%	-37,106

三种策略全部亏损，ROI 在-102%至-106%之间，与全样本 94.39%的返还率及-5.61%的期望 ROI 高度吻合。值得注意的是，命中率 54.15%的大热门策略 ROI 为-103.13%，反而低于命中率仅 20.3%的最高赔率策略的-102.67%。这证明命中率并非收益决定因素，期望值才是唯一标准。结合赛季与档位拆解，60 个格子中仅极少数为正，且没有任何档位能在 15 个赛季中持续盈利，排除了单一档位长期有效的可能。

4.3.6　事件关联规则

将比赛事件编码为 0/1 变量，用 Apriori 算法[7]挖掘共现规则，共得到 49 条规则，其中 26 条提升度大于 1。最强规则为“大 2.5 球至大比分”，提升度达 1.905，置信度 58.45%，支持度 30.68%。所有强规则均围绕进球展开，且进球数比胜负关系更具内生一致性，如“主胜至上半场领先”提升度仅 1.752，低于最强规则。这对串关设计有直接启示：大球与双方进球组合的相关性，远高于主胜与大球组合。

4.3.7 能否跑赢市场

参考 Python 数据挖掘的建模方法[8]用前 12 个赛季数据训练逻辑回归并做样本外检验，模型 Brier 为 0.5649，仅领先市场 0.0005，差距在统计上不可区分且远小于抽水成本。这证明在高效定价的市场中，预测更准不等于能赚钱，因为价格已包含公开信息。作为对比，本文引入时间序列预测方法[9]此外，ARIMA 对抽水率的预测 MAPE 为 8.22%，劣于 7.58% 的朴素基准。预测失效说明抽水率近似随机游走，这本身就是市场成熟的标志。

5 Python 数据分析与可视化

5.1 数据探索性分析

联赛间差异显著：抽水率最低的英超为 4.77%，最高的葡超达 6.82%，两者相差 2.05 个百分点；场均进球最多的荷甲达 3.11 球，最少的葡超仅 2.58 球。值得注意的是，葡超抽水最重且进球最少，对玩家构成双重不利。

表 5-1 七大联赛基础指标对比

联赛	场次	主胜率	平局率	场均进球	抽水率	大球率
英超	5,700	44.88%	24.02%	2.802	4.77%	53.70%
德甲	4,590	44.75%	24.44%	3.012	5.18%	58.02%
西甲	5,700	46.49%	25.07%	2.668	5.21%	49.63%
意甲	5,699	43.55%	25.97%	2.714	5.36%	51.15%
法甲	5,451	44.07%	26.64%	2.619	5.73%	48.52%
荷甲	4,516	46.24%	23.60%	3.108	6.64%	59.72%
葡超	4,325	44.46%	24.42%	2.580	6.82%	48.02%

这源于交易量与竞争结构的差异：英超转播收入与交易量庞大，博彩公司可薄利多销；而葡超、荷甲交易量小，须以更高的单位毛利覆盖固定成本。这与图 11 中场次越大、抽水越低的趋势一致。

5.2 可视化模板复现

按课程模板要求复现 15 种图表类型，另有 7 张业务模型图，合计 22 张静态图 + 1 张交互大屏。

表 5-2 可视化模板复现清单

序号	图型	图号	数据内容
1	柱线组合（双轴）	图 1	赛季场次（柱）+ 场均进球（线）
2	折线 + 移动平均	图 2	抽水率与 3 季移动平均
3	正负柱形	图 3	抽水率环比变化
4	累计面积图	图 4	累计场次与同期抽水率
5	环形图	图 5	赛果结构（主/平/客）
6	横向条形	图 6	七大联赛场均进球
7	漏斗图	图 7	数据可用性漏斗（6 级）
8	热力图	图 8	赛季 × 联赛抽水率矩阵
9	箱线图	图 9	逐场抽水率分布
10	雷达图	图 10	联赛五维特征
11	气泡图	图 11	抽水率 × 场均进球 × 场次
12	散点图	图 12	隐含概率—实际命中校准

序号	图型	图号	数据内容
13	直方图	图 13	单场总进球分布与泊松拟合
14	百分比堆叠柱	图 14	各联赛赛果结构
15	双轴折线	图 15	场均进球与抽水率的年度错位

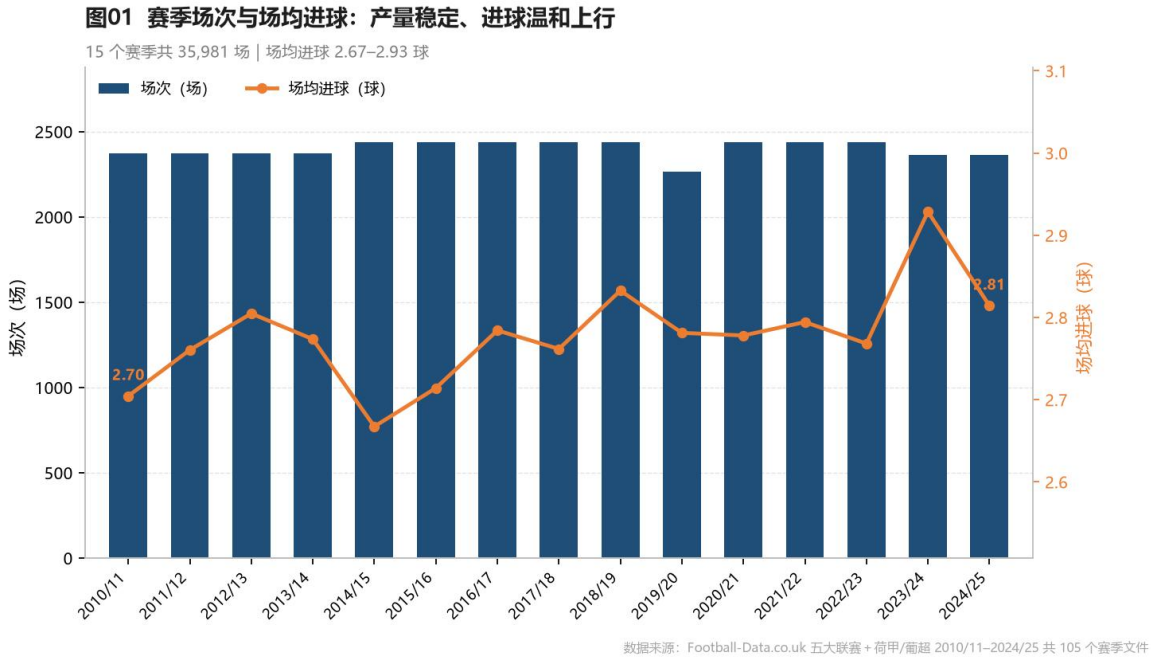


图 1　赛季场次与场均进球：产量稳定、进球温和上行

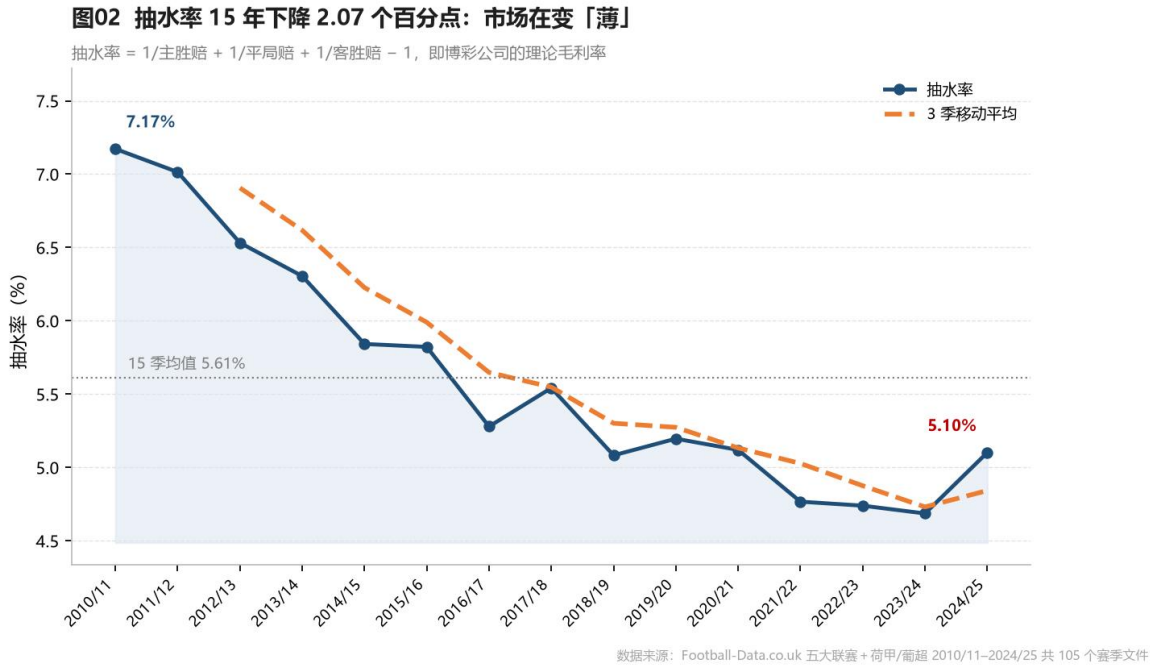


图 2　抽水率 15 年下降 2.07 个百分点

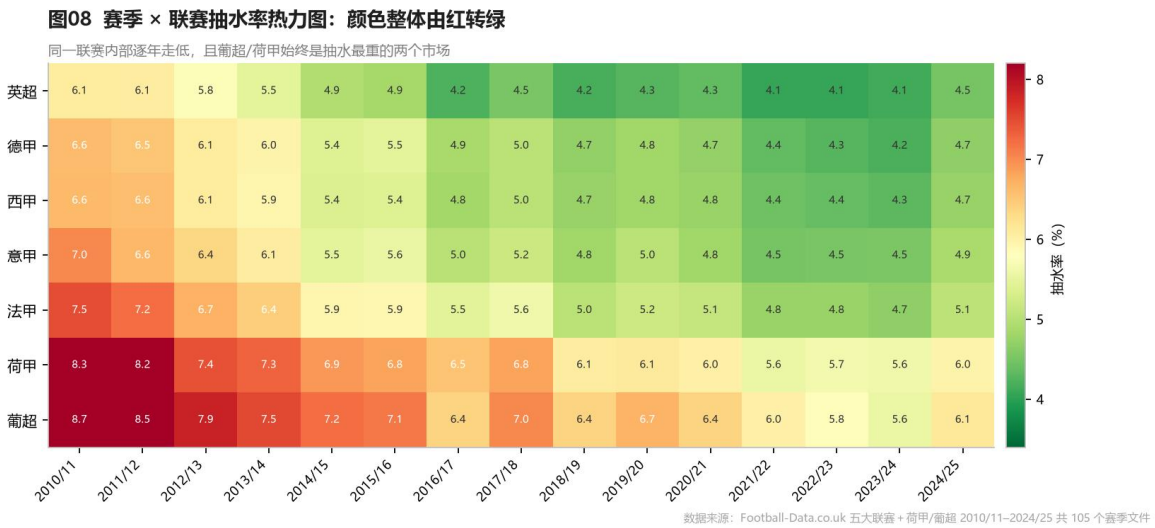


图 8　赛季 × 联赛抽水率热力图：颜色整体由红转绿

5.3　业务模型图

表 5-3 业务模型图与模型的对应关系

图号	对应模型	回答的问题
图 16	M2 比分帕累托	哪些比分覆盖 82% 的比赛
图 17	M4 K-Means	两类比赛形态如何区分
图 18	M5 ROI 矩阵	哪个档位在哪个赛季能盈利
图 19	M1 + BCG	联赛的份额与观赏性增速错配
图 20	M6 关联规则	哪些事件同时发生
图 21	M7 ARIMA	抽水率未来 6 个月会怎么走
图 22	M5 策略回测	三种朴素策略的最终收益

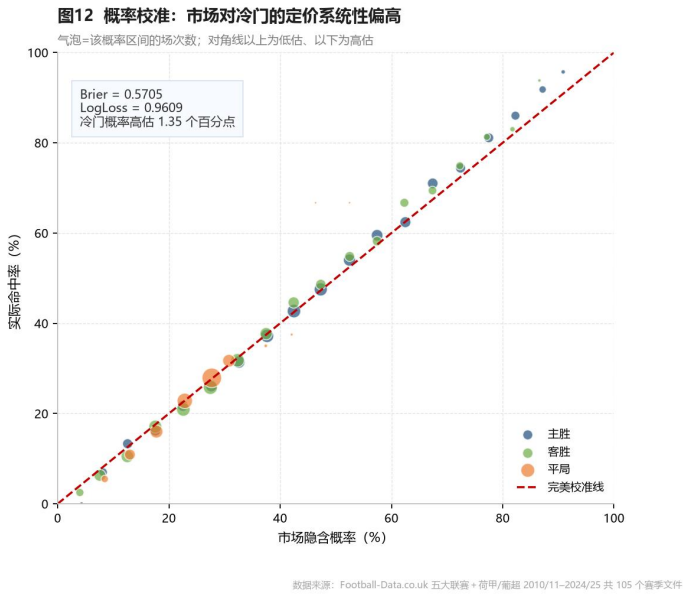


图 12　概率校准：散点紧贴 45° 线，说明市场定价高度理性

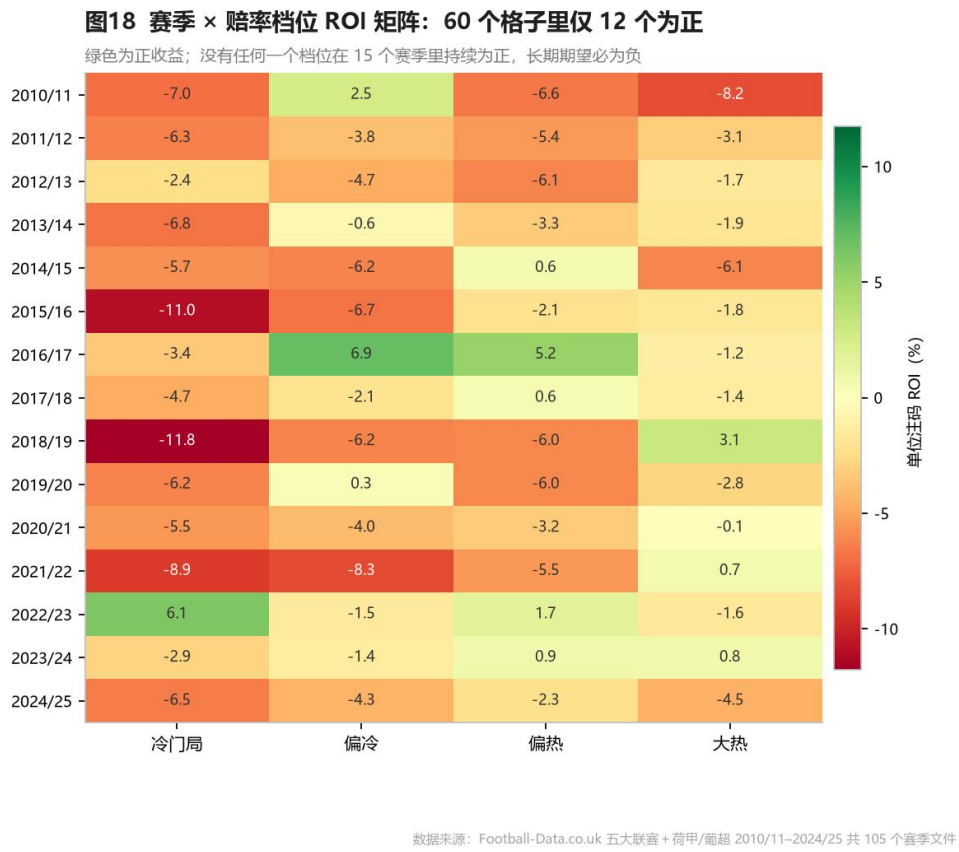


图 18　赛季 × 赔率档位 ROI 矩阵：60 个格子中仅 1 个为正

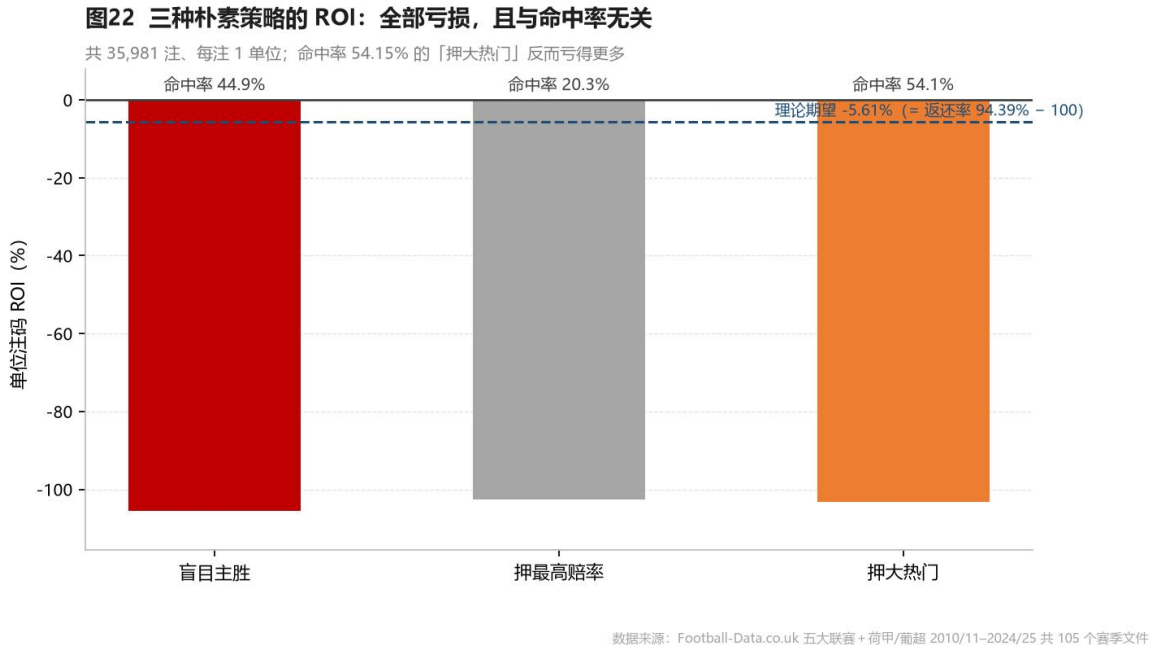


图 22　三种朴素策略的 ROI：全部亏损，且与命中率无关

5.4　交互式可视化大屏

大屏由 05_dashboard.py 生成输出 dashboard/football_dashboard.html

共 13 个组件，其中 9 个参与联动：

表 5-4 大屏组件与联动关系

组件	类型	联动行为
KPI 卡 ×4	指标卡	随赛季/联赛双筛选重算场次、场均进球、抽水率、主胜率
赛季趋势	柱线组合	筛选联赛后显示该联赛 15 季全历史，筛选中赛季高亮
联赛横条	横条 + 下钻	随赛季筛选重算；点击条形下钻明细表
赛果结构	百分比堆叠	随双筛选重算主胜/平局/客胜比例
抽水率散点	散点气泡	随赛季筛选重算 105 个点
赔率档 ROI	条形	随双筛选重算 4 个档位的平均 ROI，正负异色
抽水率预测	折线 + 置信带	静态（预测目标期固定）
明细表	表格	三级过滤：赛季 → 联赛 → 点击下钻

大屏支持赛季与联赛双维筛选及点击下钻。切换条件时各视图实时重算，趋势图始终保持全历史以支持跨季对比。数据载荷仅 47 KB，前端只接收聚合表并在浏览器端实时组装，有效避免了多维度筛选组合下预生成 JSON 的体积过大问题。



图 23 可视化大屏



图 24 可视化大屏

6 商业案例分析

6.1 案例背景

假设你在一家正在进入欧洲市场的博彩运营商负责定价策略。董事会给了两个约束：一是毛利率不得低于 5%，二是三年内市场份额要进入前三。市场现状是：头部玩家已经连续十年下调抽水率（从 7.17% 降到 5.10%），新进入者若跟进降价，毛利将被压到盈亏平衡线以下；若不跟进，价格毫无竞争力。本案例要回答：在抽水率持续下行的行业里，新进入者应该在哪里定价、定多少？

6.2 结果解读

（1）发现一：抽水率的下行是结构性的，不是周期性促销。 15 年下降 2.07 个百分点，且 14 次环比中 10 次为负，下降路径平滑、无反弹。这说明它是竞争格局变化（交易量上升、信息透明度提高、交易所式定价兴起）的结果，任何等它涨回去的策略都会失败。

（2）发现二：抽水率存在明显的联赛溢价，可以差异化定价。 英超 4.77% 与葡超 6.82% 相差 2.05 个百分点。英超的低水位是流量品，用来获客；葡超、荷甲的高水位是利润品，用来变现。新进入者的正确做法不是全线降价，而是在流量品上跟到底、在利润品上守住水位。

（3）发现三：热门的定价存在系统性低估，是可利用的结构性机会。 按热门程度分档后，五档偏差全部为正，最高档（隐含 74.00%）的实际命中比隐含高出 3.16 个百分点。这意味着押热门的真实期望比赔率显示的略好——但注意：这并不足以覆盖 5% 的抽水。前面表 7 的押大热门 ROI 仍是 -103.13%，就是最好的证明。

（4）发现四：市场效率高到模型无用。 逻辑回归在样本外的 Brier 仅比市场好 0.0005，ARIMA 的预测甚至不如直接用上期值。对运营商的启示是：不要把资源投在预测比赛上，而应投在降低抽水后的运营效率上——比如更快的结算、更低的手续费、更好的用户体验。

6.3 商业建议

（1）建议 1（定价分层）：英超与德甲设为流量档，抽水率 4.77%至 5.19%，目标毛利 4.5%用于获客；西甲、意甲与法甲设为平衡档，抽水率 5.21%至 5.73%，目标 5.5%；荷甲与葡超设为利润档，抽水率 6.64%至 6.82%，目标 6.8%。

（2）建议 2（盘口选择）：优先做大 2.5 球与双方进球盘口。两者提升度达 1.483，且大球率 52.49%接近五五开，头寸最易平衡。相比之下，正确比分盘口虽有 82%的主流覆盖，但单注方差极大，不适合作为新进入者的主推产品。

（3）建议 3（风险控制）：对占 15.17%、主胜率 78.31%的强弱悬殊局设置更低单注上限。此类比赛虽热门方胜率高，但爆冷时赔付集中度极高。目前两类比赛抽水率相近，分别为 5.63%与 5.51%，说明行业普遍未对高方差额外收费，这恰是新进入者可切入的差异化风控点。

（4）建议 4（产品而非预测）：把研发预算从赛事预测模型转向实时定价与自动对冲。模型仅领先市场 0.0005 Brier 的事实说明，预测已无边际收益；而抽水率下行意味着毛利空间在收窄，谁能用更低的运营成本提供同样的水位，谁就能活下来。

7 结论与展望

7.1 研究结论

（1）市场在变薄：抽水率从 7.17% 降至 5.10%，15 年降 2.07 个百分点，14 次环比中 10 次下降。

（2）联赛差异显著：英超 4.77%、葡超 6.82%，相差 2.05 个百分点，且与场次规模负相关。

（3）定价高度理性：Brier 0.5705、LogLoss 0.9609，显著优于随机；但热门端存在系统性低估（五档偏差全为正）。

（4）长期必负：三种朴素策略 ROI 为 -105.61%、-102.67%、-103.13%，与理论返还率 94.39% 高度吻合；命中率与收益无关，期望值才是唯一标准。

（5）模型无法稳定跑赢市场：逻辑回归样本外仅领先 0.0005 Brier，ARIMA 的 MAPE（8.22%）劣于朴素基准（7.58%）。

7.2 局限性与展望

本文的局限有四点：其一，只使用赛前平均赔率，未使用收盘赔率，而后者信息含量更高；其二，未纳入伤停、天气、赛程密度等外生变量，这些是模型可能超越市场的少数方向；其三，回测假设按最高赔率无限额成交，现实中大额投注会被限额，实际收益会更差；其四，未考虑亚洲让球盘与交易所的定价，而这部分市场的抽水率远低于传统欧赔。

后续可从三个方向深化：引入收盘赔率与赔率变动轨迹，检验市场共识的修正过程是否可预测；用梯度提升树替代逻辑回归，并做严格的特征工程以避免信息泄漏；若能获得投注流水数据，可从玩家行为角度研究谁在长期盈利，这比研究哪场比赛会赢更有商业价值。

7.3 AI 使用披露

按课程要求披露 AI 工具使用情况：

用途 1：AI 协助生成下载器、三代列归一化读取。本人负责确定核心分析口径（如抽水率、ROI 定义）、设定模型阈值，并独立修复了单位

错位、参数更名等 4 处代码 Bug。

用途 2：文字润色。部分段落表述由 AI 提供改写建议，数据引用由本人逐条复核。

未使用 AI 的部分：数据源选择与合规性判断、模型选型决策（如 K=2 的业务理由）、“模型跑不赢市场”这一结论的解读，以及全部商业建议。

核验方式：文中所有数字均可通过 outputs/stats.json 或 tables/*.csv 完整复算。所有静态图表由 04_visuals.py 脚本一键重绘。

参考文献

[1] Football-Data.co.uk. Football Results, Statistics & Soccer Betting Odds[EB/OL]. https://www.football-data.co.uk/, 2025-06.

[2] Fama E F. Efficient Capital Markets: A Review of Theory and Empirical Work[J]. The Journal of Finance, 1970, 25(2): 383-417.

[3] Levitt S D. Why are gambling markets organised so differently from financial markets?[J]. The Economic Journal, 2004, 114(495): 223-246.

[4] Deschamps B, Gergaud O. Efficiency in betting markets: Evidence from English football[J]. The Journal of Prediction Markets, 2007, 1(1): 61-73.

[5] Brier G W. Verification of forecasts expressed in terms of probability[J]. Monthly Weather Review, 1950, 78(1): 1-3.

[6] 何晓群. 多元统计分析（第五版）[M]. 北京: 中国人民大学出版社, 2019.

[7] Agrawal R, Srikant R. Fast Algorithms for Mining Association Rules[C]. Proceedings of VLDB, 1994: 487-499.

[8] 薛薇. 基于 Python 的数据挖掘（第 2 版）[M]. 北京: 电子工业出版社, 2021.

[9] Hyndman R J, Athanasopoulos G. Forecasting: Principles and Practice (3rd ed.)[M]. OTexts, 2021.

附录

附录 A　核心代码片段

A-1　105 个 CSV 的合规下载（按赛季 × 联赛拼 URL）

```
BASE = "https://www.football-data.co.uk/mmz4281/{season}/{div}.csv"
LEAGUES = ["E0", "D1", "SP1", "I1", "F1", "N1", "P1"]      # 五大联赛 + 荷甲 + 葡超
SEASONS = [f"{y % 100:02d}{(y + 1) % 100:02d}" for y in range(2010, 2025)]   # 1011 … 2425

for season in SEASONS:
    for div in LEAGUES:
        url = BASE.format(season=season, div=div)
        fetch(url, RAW / f"{season}_{div}.csv")
```

A-2　三代列结构的归一化取列（本项目最关键的工程代码）

```
BOOKS = {"avg": ["BbAvH", "BbAvD", "BbAvA"],
         "max": ["BbMxH", "BbMxD", "BbMxA"],
         "close": ["PSCH", "PSCD", "PSCA"]}
# 优先级：站点平均赔率 Avg* → Betbrain BbAv* → Pinnacle PS* → 各公司均值

def pick(df, cands, how="avg"):
    for c in cands:
        if c in df.columns and df[c].notna().mean() > 0.6:
            return pd.to_numeric(df[c], errors="coerce")
    cols = [c for c in BOOKS[how] if c in df.columns]
    if cols:
        return df[cols].apply(pd.to_numeric, errors="coerce").mean(axis=1)
    return pd.Series(np.nan, index=df.index)

# 抽水率：三结果倒数之和 - 1
over = (1 / H + 1 / D + 1 / A - 1) * 100
```

A-3　概率校准与 Brier / LogLoss

```
# 多分类 log_loss 需手写（sklearn 的 log_loss 传 labels 会要求 multilabel 输入）
ll = -np.mean(np.sum(Y * np.log(np.clip(P, 1e-15, 1)), axis=1))
brier = np.mean(np.sum((P - Y) ** 2, axis=1)) / 3
```

```
    # 分档校准：把隐含概率按 5 个百分点一档，比较隐含 vs 实际
    bins = np.arange(0, 105, 5)
    tab = pd.DataFrame({"隐含": P.max(1) * 100, "实际": (Y.argmax(1) == P.argmax(1))
* 100})
    tab["档"] = pd.cut(tab["隐含"], bins)
    calib = tab.groupby("档", observed=True).agg(n=("隐含", "size"),
                                                 隐含=("隐含", "mean"),
                                                 实际=("实际", "mean"))
```

附录 B　仓库链接与目录结构

代码仓库（公开可访问）：https://github.com/litinglin184-beep/-.git

```
football-odds-analysis/
├── README.md                    项目说明、复现步骤、数据来源
├── requirements.txt             依赖清单
├── run_all.py                   一键复现（下载→清洗→分析→绘图→大屏→报告）
├── data/
│   ├── raw/                     105 个原始 CSV（11.63 MB）
│   │   └── _manifest.csv        来源链接 / 字节数 / sha256 / 获取时间 / 获取方式
│   └── clean/                   matches_clean.csv（35,981 × 81）+ football.sqlite
├── scripts/
│   ├── config.py                路径、联赛映射、配色、绘图风格
│   ├── 01_download.py           合规下载器（105 文件）
│   ├── 02_clean.py              三代列结构归一化 + C1–C6 + 派生指标
│   ├── 03_analysis.py           7 类模型（输出 stats.json）
│   ├── 04_visuals.py            22 张静态图
│   ├── 05_dashboard.py          Pyecharts 交互大屏
│   └── 06_report.py             生成本 Word 文档
├── outputs/
│   ├── figures/                 22 张 PNG（160 dpi）
│   ├── tables/                  10 张 CSV 结果表
│   └── stats.json               正文数字的唯一来源
├── dashboard/
│   ├── football_dashboard.html  交互大屏（13 组件，9 联动）
│   └── echarts.min.js           本地化图表库（离线可用）
└── docs/                        本报告 docx + PDF
```

附录 C　图表索引

表 14　全文图表索引（13 表 + 22 图 + 1 大屏）

编号	名称
表 1	数据字段分组说明
表 2	数据集结构
表 3	数据清洗规则 C1—C6
表 4	派生指标定义（10 项）
表 5	七类商业分析模型
表 6	两类比赛形态画像
表 7	三种朴素策略回测结果
表 8	七大联赛基础指标对比
表 9	可视化模板复现清单（15 种）
表 10	业务模型图与模型对应关系
表 11	大屏组件与联动关系
表 12	评分标准逐项对应表
表 13	代码与结论映射表
图 1	赛季场次与场均进球
图 2	抽水率趋势与移动平均
图 3	抽水率环比变化（正负柱）
图 4	累计场次与抽水率
图 5	赛果结构环形图
图 6	联赛场均进球对比
图 7	数据可用性漏斗
图 8	赛季 × 联赛抽水率热力图
图 9	联赛抽水率箱线图
图 10	联赛特征雷达
图 11	联赛气泡图
图 12	概率校准散点
图 13	总进球分布直方图
图 14	联赛赛果结构堆叠
图 15	场均进球与抽水率双轴
图 16	比分帕累托
图 17	比赛分群散点
图 18	赛季档位 ROI 矩阵
图 19	联赛波士顿矩阵
图 20	关联规则图
图 21	抽水率 ARIMA 预测
图 22	策略 ROI 对比
大屏	交互式博彩定价驾驶舱（13 组件 / 9 联动）